



**UNIVERSITÀ
DI TRENTO**

**Dipartimento di
Ingegneria Industriale**

Corso di Laurea in

Ingegneria Industriale met. Meccatronica

PROVA FINALE

Reti neurali e veicoli autonomi:
criticità attuali e prospettive future

Relatore

Rech Paolo

Studente

Murgia Edoardo, Mat: 186659

ANNO ACCADEMICO 2021/2022

Indice

1	Introduzione	5
2	Reti Neurali Convoluzionali	9
2.1	Cenni Storici	9
2.2	Termini e Nozioni	10
2.3	Reti Neurali	10
2.4	<i>Loss Function e Backpropagation</i>	12
2.4.1	<i>Loss Function</i>	13
2.4.2	<i>Training e Backpropagation</i>	13
2.5	Convoluzione	14
3	Guida Autonoma	17
3.1	Albori	17
3.2	Reti Neurali e Guida Autonoma	18
3.3	<i>Competitors</i>	19
3.3.1	Tesla	20
3.3.2	Waymo	20
3.3.3	nVIDIA	21
3.4	Criticità	22
3.5	Reti Odierne	23
3.5.1	YOLO: architettura, allenamento e prestazioni	24
4	Prospettive Future	27
4.1	ADAS	27
4.2	Persistenza degli Oggetti	28
4.3	Infrastrutture	29
4.4	Proiezioni	30
	Conclusioni	33
	Bibliografia e Sitografia	35
	Ringraziamenti	39

Capitolo 1

Introduzione

I veicoli a guida autonoma (o parzialmente autonoma) sono una realtà che nel corso di questi ultimi anni sta diventando sempre più concreta. L'8 giugno 2022, con l'approvazione dell'emendamento al Regolamento UNECE n. 157, l'Unione Europea ha stabilito che da Gennaio dell'anno corrente (2023) i sistemi di assistenza al conducente di livello 3 possono funzionare fino a 130 km/h¹ [1].

Questa è probabilmente la più significativa tra quelle norme stabilite dall'UE atte a regolamentare la questione guida autonoma e che permetteranno alle Case automobilistiche di introdurre sul mercato veicoli dotati di Intelligenza Artificiale (*Artificial Intelligence*, **AI**).

I livelli di **autonomia** del veicolo sono 6 (0-5) e si differenziano in base al grado di automazione che forniscono:

- Livello 0 (nessuna automazione di guida): rappresenta il maggior numero di veicoli oggi in circolazione. Il compito di guida spetta al conducente, anche se spesso sono presenti sistemi che lo aiutano. Un esempio è la frenata automatica di emergenza, non considerata automazione poiché tecnicamente non "guida" il veicolo;
- Livello 1 (assistenza alla guida): è il livello più basso di automazione, in quanto il veicolo è dotato di un unico sistema di assistenza alla guida (sterzata o accelerazione). Solitamente si tratta del controllo adattivo della velocità di crociera, che consente di mantenere il veicolo a distanza di sicurezza dal mezzo successivo. Gli altri aspetti di guida sono controllati dal conducente;
- Livello 2 (automazione parziale della guida): è un livello avanzato di assistenza alla guida in cui il veicolo può controllare sia lo sterzo che l'accelerazione/decelerazione. Il conducente è obbligato a mantenere il controllo della vettura in qualsiasi situazione;
- Livello 3 (automazione di guida condizionata): il veicolo è in grado di guidare senza la necessità di essere supervisionato quando vengono rispettate delle particolari condizioni restrittive, relative alle situazioni circostanti e al meteo;
- Livello 4 (automazione di guida elevata): con questo livello di autonomia il veicolo è in grado di gestire quasi qualsiasi tipo di situazione, richiedendo l'intervento umano solo nei casi di estrema necessità;
- Livello 5 (automazione di guida completa): questo livello determina il massimo livello di autonomia. Non è richiesta la presenza dell'uomo per la conduzione del veicolo.

Attualmente la tecnologia più evoluta e prossima all'introduzione sul mercato da parte delle Case è l'automazione parziale della guida di livello 3 (*Conditional Driving Automation*), la quale

¹La regolamentazione può comunque essere modificata a livello Nazionale.

differisce rispetto alla sorpassata assistenza avanzata alla guida di livello 2 (*Partial Driving Automation*), in maniera sostanziale, grazie soprattutto a delle capacità di "**rilevamento ambientale**" evolute. Questo permette al mezzo di prendere delle decisioni informate, come accelerare e sorpassare un veicolo lento; è richiesta comunque la presenza dell'uomo, che deve rimanere vigile e pronto a riprendere il controllo nel caso in cui il sistema non fosse più in grado di eseguire il proprio compito [2].

Il salto tecnologico dal livello 2 al livello 3 è reso possibile dall'utilizzo di sensori più accurati (LiDAR, RADAR, telecamere) e di Intelligenze Artificiali in grado di analizzare i dati forniti in maniera più efficiente ed accurata, come nel caso della rilevazione di oggetti (**object detection** [figura 1.2]), ottenuta attraverso l'elaborazione dell'immagine mediante **Convolutional Neural Networks (CNNs)**. Queste sono un particolare tipo di Reti Neurali, la cui architettura è stata progettata prendendo ispirazione dal modello della corteccia visiva prefrontale animale. Attraverso una serie di cicli convolutivi (che verranno analizzati più avanti durante questa trattazione) sono in grado di distinguere, all'interno di una figura, i tratti di alcuni particolari oggetti, dunque di localizzarli e categorizzarli.

Nell'ambito della guida autonoma, è diventato quindi fondamentale l'impiego delle AI, una branca dell'informatica atta a studiare l'arte dell'"apprendimento automatico" da parte del Computer. In altre parole è il tentativo del calcolatore di emulare il comportamento umano, ovvero di riprodurre determinati meccanismi che per noi sono innati e naturali.

Oggi le AI sono sfruttate per l'appunto anche dai principali colossi dell'industria automobilistica e il loro studio è in costante e continua evoluzione. L'obiettivo finale è quello di raggiungere l'automazione totale della guida di livello 5 (*Full Driving Automation*), tramite cui la cosiddetta "*dynamic driving task*²" sarà eliminata. Le auto di questa categoria non richiederanno di avere volante o pedali di accelerazione/frenata e saranno prive di *geofencing*³, capaci di andare ovunque e agire come un automobilista esperto. Anche se questa tipologia di veicolo è in fase di sperimentazione in diverse parti del mondo, ancora nessuna è disponibile per il pubblico.

Da questo possibile futuro cambio radicale di paradigma si sono formate due principali scuole di pensiero, tra le quali il dibattito è ancora aperto.

Lex Fridman, professore dell'MIT di Boston, nonché uno dei principali esperti nel settore *Self Driving Vehicle (SDV)* ha dato una definizione sulle due tipologie di visione che dividono oggi le opinioni riguardo l'argomento.

Una versione utopica, per la quale le auto a guida autonoma potranno ridurre il problema dell'alta mortalità negli incidenti (172.183 incidenti solo nel 2019 in Italia [3]), causati prevalentemente dall'errore umano (95% dei casi [4]). Inoltre renderanno possibilmente non più necessario il possesso di automobili private, grazie alla diffusione di servizi di *car sharing* evoluti.

Contrariamente poi, una versione distopica, per la quale verranno eliminati numerosi posti di lavoro (basta pensare ai Taxi o in generale ai conducenti). Inoltre, nel caso di incidente provocato da un malfunzionamento del veicolo, quindi di un'entità non avente fondamento etico, ad esempio in seguito ad una **false positive detection** o ad una *missed prediction*, si creerebbe una situazione in cui sarebbe complicato stabilire a chi attribuire la colpa [5].

L'obiettivo che si prefissa questo elaborato all'interno dei prossimi capitoli, è quello di fornire la definizione di Intelligenza Artificiale, nella fattispecie delle *Neural Networks* e della loro versione convolutiva, descrivendone la struttura, le operazioni elementari che ne compongono gli algoritmi e il funzionamento di base.

Successivamente verrà analizzato come queste tecnologie possono contribuire a realizzare il

²Funzioni operative e tattiche svolte in tempo reale dall'uomo necessarie per gestire un veicolo in sicurezza nel traffico stradale.

³Perimetro virtuale associato a un'area geografica del mondo reale.

processo di guida autonoma lungo tutta la *pipeline* di implementazione, ponendo particolare attenzione a quanto la fase di rilevamento degli oggetti sia importante in tutto il meccanismo. Saranno riportati degli esempi di come alcune aziende leader del settore stanno utilizzando le architetture allo stato dell'arte e il tipo di strategia da loro scelta per proseguire nella ricerca del grado di autonomia più elevato possibile. Verranno analizzate le criticità presenti ad oggi più significative che ostacolano il processo di automazione e, infine, l'attenzione verterà sul futuro, studiando alcune proiezioni fornite da analisti del settore e provando a dedurre come evolverà la situazione nei prossimi anni.




Figura 1.1: I 5 + 1 livelli di automazione alla guida [2].




Figura 1.2: Esempio di Object Detection di oggetti multipli nel traffico ottenuto attraverso CNN [6].

Capitolo 2

Reti Neurali Convoluzionali

2.1 Cenni Storici

L'idea di rete neurale è stata concepita, senza troppa sorpresa, come modello basato sulla funzione dei neuroni umani. Il primo modello teorico di un rudimentale neurone artificiale vede la luce nel 1943. A proporlo sono il neurofisiologo Warren McCulloch e il matematico Walter Pitts, i quali descrivono un apparato in grado di ricevere in ingresso per ognuno dei suoi elementi n dati binari, a cui segue un singolo dato in uscita. Tale macchina è in grado di lavorare solo ed esclusivamente su funzioni booleane elementari. Nel 1949 lo psicologo Donald O. Hebb ipotizza la possibilità di istruire le macchine attraverso un apprendimento che emuli quello alla base dell'intelligenza umana.

Nel 1958 Frank Rosenblatt propone la prima rete neurale: *Perceptron*. Il suo impiego è parecchio ridotto, infatti si limita a riconoscere alcune forme e dividerle in gruppi separati o a calcolare semplici funzioni. Il passo successivo è stato il *Perceptron Multistrato* (MLP), in grado di computare ogni tipo di funzione.

L'importante svolta è stata data nel 1986 da David Rumelhart, Geoffrey Hinton e Ronald J. Williams i quali hanno elaborato il celebre "**Error Back-Propagation**", ovvero l'algoritmo tramite il quale si riesce a retro-propagare l'errore, utilizzato ancora oggi e fondamentale nel processo di apprendimento della rete.

Nel 1990 Jeffrey L. Elman progetta l'omonima rete: un modello ricorrente (bidirezionale) con struttura MLP, rispetto alla quale viene aggiunto un gruppo di nodi aventi lo scopo di conservare dei valori nella rete.

L'evoluzione delle *Neural Networks* prosegue con la recente tecnologia adottata da **IBM**, che utilizza materiali a cambiamento di fase (da solido cristallino a solido amorfo). L'attivazione dei neuroni (*firing*) è innescata dal cambiamento di fase stesso. Ad oggi il neurone IBM è ciò che più si avvicina all'emulazione del cervello umano, ma non permette ancora di immagazzinare informazioni in maniera stabile [7].

2.2 Termini e Nozioni

Machine Learning (ML), *Neural Networks* (NNs), *Deep Learning* (DL). Questi termini sono ormai utilizzati di frequente nel linguaggio di tutti i giorni, ma vengono spesso erroneamente usati come sinonimi e come sinonimi di Intelligenza Artificiale.

Come fatto in precedenza per l'AI, di seguito verrà data una veloce definizione in modo da poterli distinguere, dato che verranno nominati successivamente nella trattazione.

Machine Learning indica una sotto-categoria dell'Intelligenza Artificiale, che fa riferimento al processo tramite il quale i computer sviluppano il riconoscimento dei *patterns*¹. È l'allenamento con cui l'AI è in grado di apprendere continuamente dall'esperienza pregressa (esattamente come agisce l'intelligenza umana), correggendosi e arrivando a prendere decisioni autonome.

Neural Network è a sua volta una sotto-categoria del ML ed è un modello matematico in cui sono presenti dei nodi che vengono chiamati "neuroni artificiali", in quanto, dato il loro collegamento e il loro modo di funzionare, ricordano le reti neurali biologiche.

Deep Learning è una tecnica di apprendimento propria delle reti neurali, in cui si espongono queste ultime a vaste quantità di dati, in modo tale che possano "imparare" a svolgere determinati compiti [8].




Figura 2.1: Diagramma riassuntivo su *Machine Learning*, *Artificial Intelligence* e *Deep Learning* [9].

2.3 Reti Neurali

Le reti neurali, note anche come reti neurali artificiali (*Artificial Neural Networks*, ANNs) o reti neurali simulate (*Simulated Neural Networks*, SNNs), come anticipato poc'anzi, sono un sottoinsieme del *Machine Learning* e l'elemento centrale su cui si applica il *Deep Learning*. Sono dei modelli matematici la cui struttura è ispirata vagamente al cervello umano, emulandone il modo di scambiare segnali e informazioni mediante neuroni.

Le NNs sono composte da tre categorie di nodi (neuroni), che si suddividono in livello di ingresso (*input layer*), livello di uscita (*output layer*) e in quelli che vengono definiti livelli nascosti (*hidden layers*). La struttura più semplice che possono assumere è quindi composta da uno strato d'ingresso, un singolo strato centrale nascosto e uno strato d'uscita, in rispettiva successione [figura 2.3]. Questi strati sono interconnessi tra loro ed ogni connessione simula la funzione della sinapsi mediante un **peso** modificabile associato.

Nelle reti che verranno analizzate di seguito, dette *feed forward*, il segnale viene ricevuto in ingresso da un nodo e propagato in avanti come *input* allo strato successivo, senza che si creino

¹Inteso come disegno, modello o forma.

dei cicli (in questo caso si avrebbe una rete neurale ricorsiva). Ogni neurone riceve quindi informazioni sotto forma di prodotto tra il segnale in uscita dai neuroni collegati precedenti (x_i) e i pesi associati ai collegamenti che li uniscono (w_i). Viene sommato eventualmente un valore detto **bias** (b_j).

L'ingresso corrispondente ad un neurone j qualsiasi vale quindi:

$$z_j = \sum_{i=1}^n w_i \cdot x_i + b_j = w_1 \cdot x_1 + w_2 \cdot x_2 + \dots + w_n \cdot x_n + b_j \quad (2.1)$$

Il nodo applica all'ingresso (z_j) una funzione detta **activation function** (f) e restituisce in uscita l'informazione che verrà a sua volta inviata allo strato successivo ($f(z_j)$):

$$f(z_j) = f\left(\sum_{i=1}^n w_i \cdot x_i + b_j\right) \quad (2.2)$$

Esistono numerosi tipi di funzioni di attivazione utilizzate frequentemente nelle applicazioni allo stato dell'arte; qui di seguito verranno riportate le più rilevanti.

- **Soglia:** $f(z_j) = \begin{cases} 0 & \text{se } z_j \leq \text{soglia} \\ 1 & \text{se } z_j > \text{soglia} \end{cases}$

É una funzione che restituisce un risultato binario;

- **ReLU:** $f(z_j) = \max(0, z_j)$ (*Rectified Linear Unit*)

É una funzione che lascia invariato l'ingresso se questo è positivo o nullo, mentre lo azzerava se è negativo. In alcune applicazioni viene sostituita con la *Leaky ReLU Function* che permette di aggiornare in fase di *training* anche i nodi con ingresso negativo;

- **Sigmoidea:** $f(z_j) = \frac{1}{1+e^{-z_j}}$

É una funzione che "schiaccia" i valori ricevuti in ingresso e restituisce un risultato compreso tra 0 e 1;

- **Cross Entropy:** $f(z_j) = -\frac{1}{n} \cdot \sum_{i=1}^n y_t \cdot \log(y_g)$

É una funzione di attivazione applicabile solo allo strato di *output* e dà come risultato un valore probabilistico in accordo con la predizione della rete.




Figura 2.2: Diagrammi delle funzioni di attivazione sigmoidea e ReLU [10].

Il numero di nodi di *input* dipende dalla forma dei dati in entrata nella rete e dalle scelte implementative adottate, mentre il numero di nodi di *output* è determinato in base al numero di valori in uscita dal modello (se ad esempio la rete serve a distinguere 10 diverse categorie di oggetti, l'*output layer* sarà costituito da 10 neuroni).

Infine, il numero degli strati interni nascosti e di quantità di neuroni dei quali sono costituiti sono determinati dal tipo di rete costruita, quindi dalla complessità dell'operazione che deve svolgere. Essi determinano la profondità della rete.




Figura 2.3: Esempio di rete neurale semplice con pesi, *bias* e funzioni di attivazione [11].

Dati la conformazione e il funzionamento delle NNs, diventa chiaro che il punto cruciale alla base delle reti si trovi nella fase di apprendimento, ovvero nel modo in cui vengono settati i parametri (pesi e *bias*) per far sì che i risultati predetti dalla stessa si avvicinino il più possibile ai *target* desiderati. Questo avviene durante il **training**, ovvero l'allenamento/addestramento della rete. Il procedimento consiste nel sottoporre l'algoritmo ad una serie di dati (*training samples*) composti da coppie *input-output* atteso e, sfruttando le operazioni descritte all'interno dei prossimi paragrafi, nel modificare iterativamente i parametri fino al raggiungimento di un risultato soddisfacente. La bontà di una rete è legata fortemente a questa operazione, perché ne determina l'accuratezza; per questo è un processo difficile da realizzare, in quanto necessita di numerosi dati classificati correttamente (operazione svolta "a mano"²), che devono essere sottoposti alla rete il numero corretto di volte.

2.4 Loss Function e Backpropagation

La funzione di perdita (**Loss Function**) e la retro-propagazione dell'errore (**Backpropagation**) sono i meccanismi tramite i quali viene stabilito di quanto variare i pesi e i *bias* che caratterizzano le connessioni tra i neuroni. La prima fornisce un'indicazione di quanto l'*output* prodotto dall'elaborazione di un determinato *input* da parte della rete si discosti dal valore atteso relativo. La seconda sfrutta la derivabilità delle funzioni di attivazione e determinate proprietà di calcolo per procedere a ritroso e variare pesi e *bias*, in modo da trovare i valori che **minimizzano** la funzione di perdita stessa.

²Ad esempio, per il training di una CNN, l'associazione di un'immagine alla categoria di appartenenza (immagine vettura - categoria auto) deve essere svolta manualmente per creare le banche dati.

2.4.1 Loss Function

Una delle funzioni di perdita più utilizzate è l'errore quadratico medio (*Mean Squared Error*, MSE) tra l'*output* generato (y_g) e l'*output* target (y_t). Ricordando che i valori in uscita dalla rete sono funzione dei pesi e dei *bias*, possiamo scrivere che anche la funzione di perdita è funzione degli stessi, quindi:

$$MSE = L(w, b) = \frac{1}{n} \cdot \sum_{i=1}^n (y_t - y_g)^2 \quad (2.3)$$

Questo tipo di funzione ha numerose proprietà che la rendono ideale allo scopo. Per esempio la differenza è elevata al quadrato, il che permette di avere un valore di errore positivo sia con un *output* generato maggiore del *target*, che con un *output* generato minore del *target*. Nonostante ciò l'errore è comunque penalizzato dai valori con uno scostamento maggiore. Inoltre l'MSE è una funzione convessa con un definito punto di minimo globale, il che è fondamentale durante la fase di propagazione dell'errore.

2.4.2 Training e Backpropagation

Stabilito l'errore come funzione delle variabili i cui valori devono essere settati per rendere la rete accurata, si ricorre ad un approccio iterativo per riuscire ad aggiornarli. Il metodo utilizzato nella pratica è quello della **discesa del gradiente** (*gradient descent*), che consiste nel "muoversi" lungo la *Loss Function* a piccoli passi nella direzione del minimo globale. Via via i pesi e i *bias* della rete neurale verranno ricalcolati partendo da quelli già noti e dall'ultimo errore, in modo da ridurre lo stesso. Questa operazione, come anticipato, viene svolta durante il *training*, in cui il settaggio iniziale dei valori è casuale e l'algoritmo itera passando alla NN le coppie di *input-output* desiderato appartenenti alla raccolta di dati prefissata (*training sample*). Dato che, come detto in precedenza, la funzione di perdita è una composizione di funzioni dei pesi e dei *bias* (*activation functions*) o prodotto di esse ed è derivabile, l'operazione di **backpropagation** è costruita tramite alcune proprietà del calcolo differenziale [12].

- **Regola della catena:** $\frac{\delta f(x)}{\delta x} = \frac{\delta f(x)}{\delta g(x)} \cdot \frac{\delta g(x)}{\delta x}$
- **Composizione di funzioni:** $\Delta(f(g(x))) = \Delta(f \circ g) = f'(g(x)) \cdot g'(x)$
- **Regola del prodotto:** $\Delta(f(x) \cdot g(x)) = f'(x) \cdot g(x) + g'(x) \cdot f(x)$

Applicando le tre precedenti viene calcolato il **gradiente** della funzione di perdita e, procedendo a ritroso, è possibile modificare il valore dei parametri.

Date le enormi dimensioni delle banche di dati per gli allenamenti, queste vengono divise in lotti (*batches*), in modo da velocizzare il processo. I campioni d'addestramento vengono mescolati in maniera casuale e passati un numero n di volte alla rete (con n dette *epochs*). Per ogni campione vengono attuati in successione i cosiddetti *forward pass* e *backward pass*, in cui sono rispettivamente calcolati l'errore rispetto a un dato *input* e le modifiche dei pesi e dei *bias* associati.

Questo procedimento è definito **Deep Learning** e, una volta completato, se i risultati sono soddisfacenti, la NN sarà in grado di predire i risultati nell'ambito in cui è stata allenata.

A parità di struttura della rete, gioca chiaramente una fondamentale importanza la dimensione del *training sample*, ma anche il numero di *epochs* con cui si svolge l'allenamento. È necessario

infatti trovare il giusto compromesso tra un valore troppo piccolo per cui la rete non risulta abbastanza addestrata (*underfitting*) e un valore troppo grande per cui la rete subisce il fenomeno dell'*overfitting*. Questo vorrebbe dire che il processo iterativo è stato compiuto troppe volte e l'AI creata riesce a riconoscere in maniera accurata i campioni di allenamento, ma non i campioni di *test*.

Completata la fase di *training*, si passa alla fase di **testing**, in cui molto semplicemente viene scelta una banca dati di *test* (*testing sample*), composta sempre da coppie di *input-output* associato. Questa è diversa dalla banca dati di allenamento, ma contiene informazioni dello stesso tipo. Viene sottoposta alla rete applicando solo l'azione di *forward pass* e utilizzando nuovamente la funzione di perdita si possono stabilire le performance della rete costruita.




Figura 2.4: Esempio di *Feed Forward Neural Network* e *Backpropagation* [13].

2.5 Convoluzione

Dopo aver capito come funzionano e come sono composte le Reti Neurali è ora possibile scendere nel dettaglio analizzando le reti di nostro interesse: le **Reti Neurali Convolutionali** (*Convolutional Neural Networks, CNNs*). Questo tipo di rete viene utilizzato per il riconoscimento, la localizzazione e la categorizzazione di oggetti, quindi per quell'azione che viene definita **Object Detection**. Analogamente alle altre NNs, anche le CNNs hanno una struttura formata da un *input layer*, un *output layer* e numerosi *hidden layers*. Questi eseguono delle operazioni sui dati inseriti alterandoli, in modo da apprendere le informazioni specifiche dai dati stessi. I tre *layers* più diffusi sono: la convoluzione, l'unità lineare rettificata (ReLU), e il *pooling*.

Quindi in generale una CNN è composta da:

- **Livello di *input*:** costituito da un numero di neuroni adeguato alle dimensioni delle immagini da trattare. L'informazione arriva a questo *layer* sotto forma di matrice di matrici in cui sono contenute le informazioni riguardanti i *pixels*. Se ad esempio l'immagine in ingresso è in formato RGB (*Red, Green, Blue*) ed ha una dimensione di 32×32 *pixels*, la matrice avrà una dimensione di $32 \times 32 \times 3$;
- **Convoluzione:** le immagini inserite come dati di *input* vengono sottoposte ad una serie di filtri convoluzionali, ognuno dei quali estrae una determinata caratteristica (o *feature*) dalle immagini. Questo passaggio permette alla CNN di non lavorare sull'informazione generale data dall'immagine, ma di identificare particolari diversi, come per esempio i contorni delle figure, le linee verticali, le linee orizzontali, le linee diagonali etc. Anche i filtri sono

matrici (dette di *kernel*) di dimensioni solitamente minori di quella che caratterizza l'immagine. Queste vengono fatte "scorrere" sull'*input*, per ogni passo viene calcolato il prodotto scalare tra le due e il risultato posto in una nuova matrice nella posizione centrale. Così come descritta questa operazione porta alla riduzione della dimensione della matrice, perciò talvolta si attua un'operazione definita *zero padding*, la quale consiste nell'aggiunta di un numero di zeri attorno la matrice originale dell'immagine tale da consentirle di non variare le dimensioni del risultato;




Figura 2.5: Esempio di come avviene la convoluzione (senza *zero padding*) [14].

- **Unità lineare rettificata:** consente di rendere il *training* più veloce ed efficace, in quanto, come mostrato in precedenza, mappa i valori negativi a zero e mantiene solamente i valori positivi. L'operazione attuata dalla ReLU viene definita attivazione, in quanto solo le *features* attivate vengono inviate al *layer* successivo;
- **Pooling:** semplifica i dati di *input* mediante l'esecuzione di un *downsampling* non lineare, riducendo via via le misure della matrice contenente le informazioni, ma aumentandone il livello di "astrazione". In questa operazione la dimensione della matrice contenente le informazioni viene diminuita, in quanto divisa in sotto-matrici delle quali è mantenuto un solo valore. È il maggiore nel caso del *max pooling* e la media nel caso dell'*average pooling* (le due soluzioni maggiormente utilizzate);
- **Rete Neurale:** riceve come ingresso l'informazione modificata dalle operazioni precedenti e di fatto esegue la vera e propria classificazione delle immagini, utilizzando come dati di *input* le numerose *features* estratte dalle figure, che vengono passate agli *hidden layers* da cui è composta.

Semplificando pertanto lo schema di funzionamento di una CNN possiamo dire che essa è costituita da una serie di cicli: **convoluzione + ReLU + pooling**. Dopodiché i dati, che dalla forma matriciale vengono caricati in un vettore, sono passati alla NN.




Figura 2.6: Esempio di come vengono alternati i vari strati in una CNN [15].




0	0	0	0	0
0	0	-1	0	0
0	-1	5	-1	0
0	0	-1	0	0
0	0	0	0	0

(a) Kernel per aumentare il contrasto

0	0	0	0	0
0	1	1	1	0
0	1	1	1	0
0	1	1	1	0
0	0	0	0	0

(b) Kernel per sfocare l'immagine

Figura 2.7: Esempio di due matrici di *kernel* usate nella convoluzione [14].



	-2	-1	0	
	-1	1	1	
	0	1	2	

(a) Kernel per creare un bassorilievo

	0	1	0	
	1	-4	1	
	0	1	0	

(b) Kernel per evidenziare i bordi

Figura 2.8: Esempio di altre due matrici di *kernel* usate nella convoluzione [14].

Capitolo 3

Guida Autonoma

Data una spiegazione di cosa sono le reti neurali e di come funzionano, è ora possibile approfondirne l'applicazione nell'ambito della guida autonoma. Si procederà iniziando con una veloce panoramica di quelli che sono stati i primi esperimenti nel campo, passando poi a capire come le NNs sono utilizzate nei veicoli odierni, analizzando le differenze nelle applicazioni da parte dei maggiori attori dell'industria automobilistica. Infine verranno discusse le maggiori cause di inaffidabilità per quanto riguarda la **localizzazione degli oggetti**, che, come vedremo, è l'operazione a monte di tutto il processo di elaborazione in un veicolo autonomo.

3.1 Albori

Le case automobilistiche hanno cominciato a condurre esperimenti riguardanti la semplificazione della *driving task* già a partire dagli anni venti del novecento, facendo circolare per le strade, all'epoca molto meno trafficate di oggi, veicoli dimostrativi sprovvisti di conducente, governati a distanza tramite apparecchi radio. Nonostante la completa assenza di intelligenza artificiale, di reti neurali e quindi di qualsivoglia tipo di autonomia, questo fornisce il metro di quanto sia radicata all'interno dell'industria l'aspirazione a rendere realtà la guida autonoma. Una delle prime apparizioni di una rete neurale in un veicolo arriva con l'*Automatic Land Vehicle in Neural Network* (ALVINN), creato negli anni ottanta all'Università Carnegie Mellon di Pittsburgh, in Pennsylvania. È un iniziale tentativo di sfruttare le reti neurali, che avevano avuto successo negli ambiti come il riconoscimento della scrittura a mano e del linguaggio parlato, per permettere ad un veicolo di muoversi seguendo la strada. La struttura della NN con la quale è equipaggiato ALVINN è composta da solamente tre strati di neuroni: l'*input layer*, il quale riceve informazioni da una telecamera e da un telemetro laser, un singolo *hidden layer* completamente connesso e l'*output layer*, il quale indica solo ed esclusivamente l'angolo di sterzata che il veicolo deve mantenere. L'*activation function* che contraddistingue lo strato d'ingresso video è proporzionale all'intensità del colore blu dell'immagine, in quanto fornisce il maggior contrasto tra quello che è strada e quello che è non-strada nel frame analizzato. Mentre l'*activation function* riguardante l'ingresso laser è banalmente proporzionale alla prossimità dell'area corrispondente [16].

Pochi anni più tardi anche in Europa è stato lanciato il programma *Prometheus Project*, finanziato dai membri dell'Eureka, organizzazione europea per la ricerca tecnologica. Nel 1994 vengono infatti presentate a Parigi VaMP e Vita-2, costruite sulla base delle Mercedes 500 SEL. Sono progettate dall'università di Monaco di Baviera, da Ernst Dickmanns e dalla stessa Mercedes-Benz. Ora non solo l'auto è capace di comandare lo sterzo e seguire la strada, ma è anche in grado di agire su acceleratore e freni, basandosi sull'analisi dell'ambiente circostante. Nel 1995 percorre 2000 chilometri da Monaco a Copenaghen e ritorno, toccando in certi tratti la velocità di 180 km/h, avendo bisogno di rari interventi da parte del pilota [17].




Figura 3.1: Mercedes-Benz VaMP [18].

3.2 Reti Neurali e Guida Autonoma

Le auto a guida autonoma (*Autonomous Vehicles*, AV) sono dei sistemi in grado di prendere decisioni in relazione ai dati che vengono loro forniti. La *pipeline* che collega l'acquisizione di parametri ambientali e informazioni con l'attuazione del controllo è formata da 4 punti principali, in cui l'intelligenza artificiale e nella fattispecie le reti neurali sono presenti quasi ovunque.

La prima azione che deve essere implementata è la **percezione**, ovvero ciò che permette al veicolo di "sapere" cosa lo circonda. Un ottimale livello viene raggiunto tramite l'utilizzo di tre sensori: camere, LiDAR e RADAR. La combinazione di più camere (*Tesla Vision*) o di più componenti tra queste tecnologie (*nVIDIA Drive Perception*) permette di creare una ricostruzione tridimensionale dell'ambiente.

Le informazioni raccolte vengono utilizzate nella fase di **localizzazione**, ovvero nell'applicazione della *Visual Odometry* (VO). Questo è il processo tramite il quale è possibile determinare la posizione e l'orientamento del veicolo analizzando la corrispondenza di punti chiave in fotogrammi di video consecutivi. In questa fase è fondamentale l'utilizzo delle reti neurali convoluzionali e del *deep learning*, per potenziare le capacità della VO, permettendo di riconoscere e classificare i vari oggetti presenti nelle immagini e stimarne a loro volta la posizione.

Capire le azioni delle cose o delle persone che circondano il veicolo è un compito molto difficile, in quanto esse coinvolgono più spesso le emozioni piuttosto che la logica. Siamo nell'ambito della **previsione**; l'obiettivo è infatti quello di predire le azioni degli altri utenti della strada o dei pedoni, in modo da poter reagire di conseguenza. Ad esempio, data la visione a 360 gradi della vettura ottenuta durante la fase di percezione, gli algoritmi basati sul *deep learning* ricevono come *input* gli stati precedenti di un veicolo circostante (velocità, posizione, direzione) e ne predicono una serie di possibili azioni. L'AI viene allenata in precedenza tramite dei *training samples* contenenti situazioni reali in modo che durante l'uso sia in grado di proporre soluzioni ottimali che comprendano frenare, accelerare, fermarsi, cambiare corsia, etc.

La parte più complessa rimane comunque quella di scegliere tra le varie opzioni di reazione, operazione che avviene durante la fase di **decision-making**. Il tipo di reti neurali utilizzato in questo ambito viene allenato attraverso un processo denominato *deep reinforcement learning* (DRL) e, nello specifico, l'algoritmo in grado di portare il veicolo a prendere decisioni è chiamato *Markov Decision Process* (MDP). Questo è un modello matematico capace di formare un processo decisionale nelle situazioni in cui i risultati sono in parte casuali e in parte sotto il controllo di un decisore ¹ [19]. In generale il *decision making* è un processo gerarchico che si sviluppa in 4 fasi:

¹Argomento non affrontato all'interno di questa trattazione.

1. Inizialmente viene compiuta la scelta del tragitto, trovando quello ottimale tra i percorsi presenti. Avviene nel momento stesso in cui è inserita la destinazione, ancor prima di cominciare il movimento;
2. Programmata la rotta l'auto deve spostarsi; è a conoscenza delle costanti che caratterizzano il percorso, quindi la strada, gli incroci e così via. L'elemento variabile è dato dagli altri umani e dalle traiettorie che effettueranno. In base a questo viene scelta l'azione da compiere tramite l'MDP;
3. Successivamente viene pianificato il movimento stesso del veicolo, ovvero la modalità con cui verrà compiuta l'azione appena decisa. Al di fuori delle manovre di emergenza questa dovrà essere confortevole per i passeggeri;
4. Infine, nella vera e propria fase di controllo del veicolo viene indicato agli attuatori come devono agire per garantire le decisioni prese in precedenza.




Figura 3.2: Rappresentazione della *pipeline* percezione-controllo [20].

3.3 Competitors

Tesla è stata la prima azienda a commercializzare un veicolo equipaggiato con un sistema di guida autonoma su larga scala. Nel 2014 il *Tesla Autopilot system*, che garantiva il livello 2 di autonomia, ha fatto il suo debutto sulle vetture della casa. Waymo (Google) ha cominciato a testare i suoi AVs già dal 2009 e, ad oggi, ha completato in totale svariati milioni di km. Questo risultato è stato raggiunto anche grazie ad un servizio di taxi inaugurato nel 2018 a Phoenix, in cui il 5-10% delle corse giornaliere sono prive di conducente [21]. nVIDIA Corporation, azienda tecnologica statunitense, è entrata sul mercato più recentemente. Il suo approccio è stato diverso dagli altri *competitors*; piuttosto di sviluppare completamente un veicolo autonomo, si è dedicata alla progettazione della tecnologia inerente alle AI necessarie ad implementare la guida autonoma stessa, rendendola applicabile a qualsiasi vettura. Presentando la sua prima versione di nVIDIA Drive PX nel 2015, seguita dalla PX2 nel 2016, ha creato i primi modelli di *hardware*, oltre che di *software*, a disposizione delle Case, con le quali in seguito ha stretto dirette collaborazioni.

Oltre ad aver visto dove e come le reti neurali sono utilizzate nel campo della guida autonoma, è interessante capire quali soluzioni i vari *competitors* hanno adottato riguardo il *training*. Questo è un aspetto fondamentale perché causa diretta dell'efficienza e dell'affidabilità stesse della rete.

3.3.1 Tesla

Solo nel 2022 Tesla ha prodotto più di 1.3 milioni di veicoli ², per un totale di oltre 3.3 milioni di automobili vendute dal 2018 al 2022 [23]. Avere una flotta così numerosa ogni giorno sulla rete stradale, comporta il fatto di ricevere un abbondante flusso di dati utilizzabili in fase di addestramento. Dato il principio generale per cui "*more training data leads to better performance*"³, lo sviluppo di questa azienda è abbastanza promettente. La strategia è infatti quella di avere un'elevata presenza di veicoli sparsi sul territorio, equipaggiati con tecnologie in grado di garantire il livello 2 (o 3 in alcuni casi) di guida autonoma, in modo tale da assicurare un costo accessibile. Nel campo della **object detection** è infatti fondamentale avere quanti più esempi possibili di tutte le variabili che si potrebbero incontrare per strada. Uno dei punti di forza dell'azienda a riguardo è che, ogni qualvolta la NN di una vettura riconosce un soggetto che appare raramente durante il percorso, come ad esempio un cavallo, viene compiuta un'istantanea, la quale sarà in seguito inviata alle sedi dell'azienda, preservando l'anonimato del cliente. Questo canale di comunicazione flotta-fabbrica può essere percorso anche al contrario. Come spiega Andrej Karpathy (ex Sr. Director delle AI in Tesla) in caso di predizione errata da parte della rete neurale di un oggetto è inviata alle auto la richiesta di mandare quante più immagini possibili all'interno delle quali viene riconosciuto il *pattern* che ha causato la *missed prediction*. Un esempio a tal riguardo è quello per cui le AI hanno riscontrato delle difficoltà nel categorizzare correttamente una vettura che stava trasportando una bicicletta su un portapacchi montato posteriormente [figura 3.3]. Trovato il problema è stata inviata richiesta alla flotta di immagini simili, le quali, inserite all'interno della raccolta utilizzata nella fase di addestramento con l'etichetta corretta, lo hanno risolto. Un approccio simile è sfruttato nel campo di allenamento della fase di **previsione**, per il quale vale lo stesso principio. Anche qui, per ogni previsione errata da parte della NN, ovvero quando viene ipotizzato un movimento di un utente diverso da quello riscontrato realmente, viene creata un'istantanea contenente i dati relativi al caso (stati precedenti del soggetto), che inviata ai *server* entrerà a far parte dei *training samples*.



Figura 3.3: Esempio delle immagini contenenti il *pattern* richiesto inviate dalla flotta [20].

3.3.2 Waymo

Waymo ha adottato un approccio completamente diverso da quello di Tesla: un numero contenuto di veicoli (servizio di taxi per il trasporto di persone)⁴, equipaggiati in modo tale da garantire almeno il livello 4 di guida autonoma. Ciò significa che sono in grado di muoversi in maniera totalmente automatica, nonostante la presenza di un guidatore facente funzione di sicurezza o, in determinati contesti, completamente senza pilota. Le auto sono dislocate principalmente in due località, Phoenix (Arizona) e San Francisco (California), dove sono in grado di circolare

²1.369.611 auto prodotte nel 2022 nonostante le pause dovute alle politiche zero Covid [22].

³Un maggior numero di dati di addestramento porta a una migliore prestazione.

⁴Circa 700 attualmente in circolazione.

solo ed esclusivamente in zone precedentemente mappate, non solo dal punto di vista della navigazione, ma anche da quello ambientale. Devono essere accuratamente individuati tutti gli agenti fissi presenti sulle strade: spartitraffico, infrastrutture di segnaletica verticale e marciapiedi, ma anche parcheggi e aree di sosta. Da qui deriva il numero limitato di città in cui il servizio è fornito. Data una flotta così limitata di veicoli, le reti neurali che vi sono inserite richiedono un approccio nella raccolta di dati da utilizzare per l'addestramento completamente diverso da quelli visti in precedenza. L'AI implementata dall'azienda viene definita *the World's Most Experienced Driver*⁵ e viene allenata, e successivamente testata, in un ambiente chiuso al traffico prima di fare il proprio debutto su strada. Waymo ha infatti a disposizione il complesso di un ex base aeronautica in California, di circa 113 acri, all'interno del quale può ricreare l'ambientazione di diversi scenari critici e capire come reagirebbe di conseguenza il veicolo. I dati raccolti vengono a loro volta utilizzati durante la fase di *training* per migliorare il comportamento. Come brevemente introdotto in precedenza, data la diversa natura dei veicoli, il numero e la qualità dei sensori sono completamente diversi da quelli di Tesla, il che permette una raccolta di dati da inserire nei campioni di allenamento sensibilmente più accurata. Grazie all'elevata qualità delle registrazioni (video, RADAR e LiDAR), i più di 32 milioni di chilometri percorsi dai veicoli sulle strade delle due città americane, si traducono in più di 32 miliardi di chilometri prodotti tramite **simulazioni** [24]. Ad esempio, se uno dei veicoli compie una banale svolta a destra a Phoenix, la scena può essere riprodotta inserendo nuove variabili che rendono la decisione più complicata, come un attraversamento pedonale percorso da una bicicletta o un veicolo accostato che riprende la marcia. Questo metodo garantisce alla rete neurale di imparare dalle situazioni reali a cui viene sottoposta durante il servizio, ma di non essere limitata dal numero di ore effettivamente guidate.




Figura 3.4: Esempio di come l'area in cui possono circolare i taxi di Waymo sia limitata all'interno di alcune zone di Phoenix [21].

3.3.3 nVIDIA

nVIDIA è una delle aziende leader nell'ambito dell'intelligenza artificiale a livello mondiale, quindi, seppur sia entrata nel mondo della guida autonoma da un lasso di tempo relativamente breve rispetto agli altri attori in scena, gode di un *know how* abbastanza vasto da sviluppare tecnologie innovative in questo campo. Nasce infatti nel 1993 come produttore di unità di elaborazioni grafiche (*Graphic Processing Unit*, GPU) [25], componenti *hardware* fondamentali nell'ambito del *machine learning*, in quanto, grazie alla loro architettura, sono in grado di svolgere migliaia di operazioni (poco complesse) in parallelo. Essendo l'esecuzione delle convoluzioni il processo più oneroso del *deep learning*, poiché composto da calcoli estremamente numerosi (in relazione alla

⁵Il pilota più esperto al mondo.

complessità della rete), ma "semplici" (prodotti scalari tra matrici), le GPU sono di conseguenza le componenti più efficienti da utilizzare per compiere l'incarico.

In seguito alla crescente domanda di questo genere di prodotti, imposta dal sempre più frequente sfruttamento delle AI anche nell'ambito della guida autonoma, l'azienda ha deciso di partecipare direttamente allo sviluppo: la strategia adottata allo scopo si pone nel mezzo tra le due viste in precedenza. Le collaborazioni che nVIDIA sta stringendo con i marchi automobilistici leader del settore⁶ hanno come obiettivo quello di ottenere una flotta in grado di percorrere più chilometri possibile per ricavare di conseguenza molti dati. Le auto in questione saranno equipaggiate con sensoristica in grado di mappare e virtualizzare l'ambiente attraverso cui viaggiano, il che, unito all'utilizzo del servizio DeepMap⁷ permetterà all'azienda di accedere a centinaia di migliaia di chilometri di strada virtuali. La mappa che viene creata è definita *Earth-Scale Digital Twin*⁸ e non è solamente una riproduzione virtuale di ricostruzione ottica, ma contiene più strati di **localizzazione**, tra i quali compaiono anche quello RADAR e LiDAR. Una volta che un dato scenario è riformato all'interno di una simulazione, può essere utilizzato come base per diverse variazioni dello stesso (cambi di traiettoria di un veicolo imminente o aggiunte di ostacoli lungo il percorso [figura 3.5]). L'ambiente formato è talmente accurato che può coprire **due** delle fasi importanti nella creazione di una rete neurale: il *training*, certo, ma anche il *testing*; è persino possibile la variazione delle condizioni ambientali, l'aggiunta di pioggia, nebbia o neve. Questo approccio consente ad nVIDIA di ricreare dati di allenamento e di test illimitati, seppur richiedano ancora un enorme sforzo umano dal punto di vista ingegneristico.



Figura 3.5: Esempio di come un soggetto virtuale (bambino) può essere aggiunto ad uno scenario reale [26].

3.4 Criticità

Le diverse azioni che compongono la *pipeline* in cui è suddivisa la guida autonoma dipendono in maniera preponderante dalla **localizzazione degli oggetti**. Quindi alle criticità che già rendono difficile l'implementazione di fasi come **previsione**, o **decision making**, si sommano i problemi e gli errori che sorgono nella fase di *computer vision* e si ripercuotono a cascata su tutto il processo a valle. È fondamentale pertanto sottolineare quali sono gli aspetti che oggi risultano ancora critici e non permettono di fare completamente affidamento sull'*object detection* compiuta dalle reti neurali (nel contesto della guida autonoma).

⁶Mercedes-Benz, Volvo (Polestar) e Jaguar-Land Rover tra questi.

⁷Compagnia californiana di *software* che si occupa di creare mappe in alta definizione per veicoli a guida autonoma.

⁸Copia digitale a grandezza naturale.

Seppure l'accuratezza totale nell'identificazione e categorizzazione degli oggetti abbia raggiunto livelli soddisfacenti, è ancora possibile incorrere in uno di questi casi:

- **Falso Positivo (*False Positive*, FP):** un'istanza di una data categoria è presente nella previsione, ma non nella realtà. Ad esempio una nuvola dalla forma particolare potrebbe essere interpretata come un oggetto presente nell'immagine;
- **Falso Negativo (*False Negative*, FN):** un'istanza di una data categoria è presente nella realtà, ma non nella previsione. Ad esempio una bicicletta presente nell'immagine che non viene riconosciuta e pertanto non evidenziata;
- ***Out of Distribution* (OOD):** un oggetto che non rientra nelle categorie con le quali la NN è stata allenata appare e non viene riconosciuto.

Ognuna di queste tre situazioni provoca un errore che può condurre a importanti conseguenze sia nella scelta delle traiettorie che in quella del comportamento. Inoltre, la percentuale di errore aumenta sensibilmente se i sensori che registrano le immagini sono sottoposti ad intemperie. Forte pioggia, neve, ma anche inclinazioni particolari dei raggi solari potrebbero creare errori nell'analisi dei frame.

Un'altra problematica che sorge è la necessità di processare le immagini **in tempo reale**, quindi l'elaborazione deve essere il più veloce possibile, cercando di tenere il passo con il *frame rate* dei dati forniti dai sensori di cui è munito il veicolo. Il compromesso per questa operazione deve essere raggiunto su due fronti: il primo è quello dell'accuratezza, infatti, più velocemente viene eseguita l'analisi delle immagini più errori vengono commessi in termini di FPs e FNs. Il secondo è quello del "costo computazionale", in quanto maggiore è il peso dei calcoli eseguiti, maggiore è la potenza richiesta. Questo impatta sulle dimensioni e sui costi dell'*hardware* presente nell'auto. Ad aumentare il tempo di analisi, oltre a quello richiesto dalle operazioni condotte dalla rete neurale, detto tempo di latenza, è il tempo di *jitter*, causato dallo spostamento dei "pacchetti" di dati lungo la struttura della NN.

Come ricorda Lex Fridman in una sua conversazione con Elon Musk, tenuta durante la terza partecipazione dell'AD di Tesla al Lex Fridman podcast, ci si dimentica di dare il meritato credito al sistema visivo umano. La rapidità nel localizzare e categorizzare oggetti è una qualità fondamentale che deve essere raggiunta dalle AI, per cercare di pareggiare il sistema biologico; in quanto le complesse infrastrutture tramite le quali devono viaggiare i veicoli autonomi sono studiate sulla base delle percezioni umane.

3.5 Reti Odierne

Al giorno d'oggi esistono varie soluzioni implementative delle reti neurali convoluzionali in grado di attuare l'*object detection*; si dividono principalmente in due diverse categorie e differiscono per logica di funzionamento. Ogni architettura conduce al medesimo risultato in termini di compito, ma non di prestazioni. Le richieste che devono soddisfare sono consecutivamente quella di localizzare gli oggetti di interesse, tracciandone le cosiddette *bounding boxes* (rettangoli di selezione) e quella di individuare la categoria di appartenenza. Gli algoritmi sono classificabili come *Two-Stage detectors* o *One-Stage detectors*:

- ***Two-Stage detectors*:** i cosiddetti *decoders* a passata doppia compiono due passaggi sull'immagine d'ingresso per predire la presenza e la posizione degli oggetti. Il primo genera una serie di proposte delle potenziali posizioni, il secondo le rifinisce e conduce alla predizione finale della rete. Questo approccio è accurato, ma lento e costoso dal punto di vista computazionale;

- **One-Stage detectors:** i cosiddetti *decoders* a passata singola compiono un solo passaggio sull'immagine d'ingresso per predire la presenza e la posizione degli oggetti. Questo approccio li rende efficienti dal punto di vista computazionale, perciò più veloci, ma, nel complesso, meno accurati.

Considerate le necessità derivanti dall'applicazione delle reti neurali alla guida autonoma, oggi le case automobilistiche prediligono l'utilizzo di una *convolutional neural network* a passata singola, denominata YOLO (*You Only Look Once*⁹).

3.5.1 YOLO: architettura, allenamento e prestazioni

Seguendo un approccio diverso rispetto alle proposte presentate in precedenza, la versione allo stato dell'arte di YOLO batte con largo margine gli altri algoritmi di localizzazione e categorizzazione in **tempo reale**.

In generale l'architettura riceve come ingresso l'immagine ed attraverso una CNN profonda ne rileva gli oggetti raffigurati. L'*input* viene diviso in una griglia di dimensioni $S \times S$ e, se il centro di un oggetto corrisponde al centro di una data cella, questa ne è responsabile dell'individuazione. Per ognuna delle aree di suddivisione viene predetto un numero B di *bounding boxes*, descritte rispettivamente da: i valori di centro rispetto ai bordi della griglia (x,y) , le dimensioni (h,w) , un valore detto "*Confidence Score*". Quest'ultimo indica quanto una *bounding box* abbia la probabilità di contenere un oggetto e contemporaneamente quanto dimensioni e localizzazione siano precise rispetto all'oggetto stesso. Inoltre, per ogni cella è predetta la probabilità condizionata per la quale l'oggetto contenuto appartenga a qualunque delle N classi in esame, generando quindi N valori di probabilità. Con questi dati il modello è in grado di indicare sia quanto è probabile che un oggetto di una data classe sia presente in una specifica *bounding box*, che quanto accuratamente lo stesso rettangolo di selezione delimiti i contorni dell'oggetto [figura 3.6]. L'architettura di YOLO è composta da un totale di 24 *convolutional layers*, ai quali succedono 2 *fully connected layers*¹⁰ [figura 3.7]. L'addestramento della rete e dei suoi strati avviene in due fasi diverse: la prima, detta *pre-training*, durante la quale, utilizzando la raccolta dati *ImageNet*¹¹, sono addestrati solo i primi 20 strati, ai quali viene aggiunta un'operazione di *average pooling* e uno strato interamente connesso. La seconda, il vero e proprio *training*, in cui gli ultimi due strati pre-addestrati vengono eliminati e rimpiazzati con 4 nuovi livelli convolutivi più 2 strati completamente connessi. Ottenuta così l'architettura finale della rete è possibile svolgerne l'addestramento ultimo. La *Loss Function* utilizzata per questo algoritmo deve tenere conto non solo dell'accuratezza rispetto alla predizione della categoria di appartenenza di un oggetto, ma anche della precisione nel tracciamento delle *bounding boxes*. Questa viene quantificata come funzione dell'*Intersection over Union* (IoU), ovvero il rapporto tra l'intersezione delle aree delle *bounding boxes* predetta e reale con la somma delle due [figura 3.8].

Dalla sua prima versione introdotta nel 2015, l'architettura si presenta oggi nella sua settima forma (YOLOv7), che consente prestazioni mai raggiunte dalle versioni precedenti [28]. È infatti in grado di processare immagini con una risoluzione di 608×608 *pixels*, ad una velocità di 155 *frames* al secondo (nella versione YOLO originale erano 45). Anche il valore di precisione IoU del 37.2% ne conferma la validità rispetto alle altre classi di reti.

Nonostante sia un ottimo algoritmo adatto alla *real-time object detection*, necessaria negli AVs, non è affatto esente dalle criticità presentate nel paragrafo precedente.

⁹"Osservi una sola volta". Riferito al metodo di analisi dell'immagine di questo tipo di rete.

¹⁰Ogni neurone è collegato a tutti i neuroni dello strato precedente e successivo.

¹¹*Database* di più di 14 milioni di immagini per l'allenamento delle reti neurali [27].

Più precisamente:

- Fatica a riconoscere oggetti di piccole dimensioni, soprattutto quando questi sono immersi in un contesto molto affollato o distanti dalla telecamera;
- Riscontra problemi nell'identificare correttamente quegli oggetti che appaiono in una scala diversa rispetto agli altri presenti;
- É molto sensibile alle variazioni della luce a cui è sottoposta la telecamera;
- Nonostante la natura "snella" del processo ad una singola passata, risulta ancora pesante per alcune applicazioni che hanno a disposizione poca potenza di calcolo.




Figura 3.6: Esempio del processo di elaborazione dell'algoritmo [29].




Figura 3.7: Struttura di rete YOLO: 24 *convolutional layers* e 2 *fully connected layers* [30].




Figura 3.8: *Intersection over Union* (IoU) [30].

Capitolo 4

Prospettive Future

Avendo dato uno sguardo alle reti neurali e a come queste influenzino il processo di guida autonoma, si può ora passare ad affrontare questo ultimo capitolo dell'elaborato. Verrà inizialmente data una spiegazione di come e quanto le tecnologie di cui già oggi disponiamo influenzino la sicurezza stradale e di come potranno migliorarla ulteriormente in futuro. Di seguito sarà introdotto il concetto di **persistenza degli oggetti**, una tematica che sta ricevendo particolare attenzione, e delle sue possibili risoluzioni. Infine si concluderà analizzando alcune proiezioni proposte da analisti specializzati nel settore.

4.1 ADAS

Uno studio completato grazie alla collaborazione Bosch-ACI nel 2019 [31], dimostra come si potrebbe ottenere una riduzione del numero di incidenti altamente impattante, se tutte le vetture fossero equipaggiate con degli efficaci sistemi di assistenza alla guida (ADAS¹). La stima raggiunge la quota del 50%, quando si considera il confronto tra i più sicuri veicoli moderni con quelli immatricolati da più di 15 anni. L'indagine si sofferma in particolare sui benefici garantiti dall'impiego del sistema di frenata automatica di emergenza: alcuni modelli dotati di questa tecnologia hanno, infatti, il 38% di probabilità in meno di essere coinvolti in un incidente.

Date queste eloquenti cifre, nel corso del 2022, l'Unione Europea ha stabilito che ogni modello di nuova omologazione dovrà essere equipaggiato con una lunga serie di sistemi di sicurezza [32]: questa è attiva, come nel caso del *lane keeping assist*², del *cruise control* adattivo³ e della frenata d'emergenza, o passiva, come nel caso degli airbag, della carrozzeria a deformazione controllata e delle cinture di sicurezza.

L'utilizzo degli ADAS che sono disponibili ad oggi può essere estremizzato, come è avvenuto dagli ultimi mesi del 2022 in poi, quando Tesla ha sbloccato, per alcuni dei suoi clienti⁴, la funzionalità *Full Self-Driving Beta*. Pur rimanendo legalmente una forma di assistenza alla guida (livello 2), questa permette di fatto ai veicoli di circolare per interi tragitti, anche in zone trafficate, senza richiedere l'intervento umano. La supervisione rimane quindi obbligatoria, in quanto la tecnologia ha ancora importanti limiti nei confronti della sicurezza (come mostrato nel capitolo precedente). A tal proposito, all'interno dell'abitacolo è presente una telecamera incaricata di controllare il conducente; se si distrae, il veicolo domanda ripetutamente di riprendere il controllo. Quando ignorato, il sistema effettua una manovra di stop in sicurezza del veicolo e attribuisce al proprietario uno *strike*. Dopo cinque ammonizioni, la funzionalità di "Pilota Automatico" viene

¹ *Advanced Driver Assistance Systems*.

² Controlla che il pilota mantenga la corsia di marcia. In alcuni casi funziona anche senza la presenza delle mani sul volante per brevi lassi di tempo.

³ Permette di seguire il veicolo precedente mantenendo la distanza di sicurezza.

⁴ Scelti in base alla posizione geografica e al tipo di "pacchetti" aggiunti in fase di acquisto.

disabilitata direttamente dalla casa e l'auto ritornerà ad avere le più comuni assistenze alla guida. L'attenzione e la responsabilità sono quindi ancora imputabili completamente al conducente, che, per il momento, deve sfruttare le automazioni del mezzo per quello che sono: assistenze.

Lo stato di condizione del pilota ha guadagnato molta importanza nell'ultimo decennio, tanto che, anche il rilevamento perdita di attenzione e sonnolenza del guidatore, il rilevamento distrazione del guidatore e la predisposizione al blocco avviamento con etilometro, sono alcune delle novità che diventeranno obbligatorie.

Il passaggio ad una realtà in cui gran parte delle responsabilità vengono invece cedute all'intelligenza artificiale, quindi ad un livello di sicurezza auspicato ancora maggiore, è ostacolato da fattori che spesso potrebbero trovare soluzioni anche al di fuori delle mura delle singole aziende produttrici di veicoli.

4.2 Persistenza degli Oggetti

Nell'ambito della *computer vision*, uno dei compiti più difficili da portare a termine è quello di creare uno spazio vettoriale (ricostruzione virtuale dell'ambiente circostante il veicolo) che sia in grado di "ricordare" alcuni dettagli in cui l'auto si imbatte durante il percorso. Questo è fondamentale nel momento in cui la visuale su un elemento chiave viene ostruita da un'occlusione. Ad esempio, durante la marcia, potrebbe capitare il caso di incontrare un veicolo ingombrante accostato, dietro il quale sono fermi dei pedoni in procinto di attraversare la strada. Questi sono visibili prima di avvicinarsi al mezzo, ma scompaiono dalla portata dei sensori negli istanti successivi, in quanto occultati dall'ostacolo. È quindi fondamentale che nel processo di **predizione** sia tenuto conto del potenziale pericolo causato dall'attraversamento.

Per l'essere umano la **persistenza degli oggetti** è una consapevolezza che viene appresa durante i primi mesi di vita, mentre, per l'intelligenza artificiale, non è ancora stato trovato un compromesso efficiente per renderla implementabile. Un'evoluzione fondamentale nella realizzazione della guida autonoma è, quindi, quella di avere memoria attraverso spazio e tempo, aggiungendo di conseguenza un "costo" all'operazione. Ricordare, infatti, per l'IA è complicato; non è chiaro per quanto a lungo sia necessario farlo e nel contempo si rischia di esaurire lo spazio di archiviazione disponibile.

In tal senso, si stanno studiando alcuni nuovi tipi di reti neurali, che permetterebbero all'intelligenza artificiale di includere il fattore **tempo** nell'analisi delle scene. Le più promettenti in fase di sviluppo sono due: le Reti Neurali Ricorsive (*Recurrent Neural Networks*, RNNs), che aggiungono un ciclo di *feedback* in grado di produrre un meccanismo simile alla memoria a breve termine umana; le *Spiking Neural Networks* (SNNs), che, invece, sono basate su un architettura completamente diversa dai modelli analizzati in precedenza, anche dal punto di vista *hardware*. Questo nuovo tipo di sistema viene denominato *Neuromorphic Computing* e permette alla rete di usare segnali dinamici, come avviene per il cervello umano, rendendola in grado di imparare in tempo reale, elaborando informazioni spazio-temporali. Dal punto di vista pratico, però, nessuna delle due è ancora abbastanza sviluppata per essere utilizzata all'interno di impieghi reali.

Al momento, una possibile parziale soluzione al problema, potrebbe essere quella di fare affidamento su un sistema infrastrutturale connesso, in grado di dialogare con i veicoli. Questo permetterebbe di avere una visuale migliore e più ampia, garantendo una costruzione dello spazio vettoriale che includa altre prospettive oltre a quella del mezzo.

4.3 Infrastrutture

Sebbene criticità come la persistenza degli oggetti o la velocità di elaborazione dei dati potranno essere risolte anche tramite il progresso delle reti neurali, altre situazioni rimangono senza soluzione, perciò, potenzialmente problematiche; ne sono un esempio gli incroci a scarsissima visibilità.

Con il proposito di risolvere queste difficoltà, ha lavorato un consorzio⁵ facente riferimento a Bosch, che, a partire dal 2018, ha utilizzato la città di Ulm (Germania) come banco di prova per uno studio sulle auto a guida autonoma, denominato MEC-View [33]. Durante questo progetto i lampioni posizionati in alcuni punti critici della rete stradale sono stati equipaggiati con telecamere, sensori LiDAR e RADAR, garantendo una chiara panoramica, da un'altezza massima di sei metri, di quello che succede negli incroci più trafficati. Infatti, la visuale da terra del solo veicolo non è sempre sufficiente a renderlo consapevole di tutte le variabili circostanti: un'altra auto potrebbe sopraggiungere da un'entrata secondaria nascosta, o un ciclista potrebbe essere coperto da un veicolo che, in un secondo momento, cambia corsia. Perciò, i dati raccolti dai sensori dell'infrastruttura vengono combinati con delle mappe in alta definizione e, successivamente, inviati al veicolo, cosicché questo li possa usare, combinandoli alla sua visuale, per decidere la manovra ottimale. Questo tipo di operazione viene definito V2I, ovvero lo scambio di informazioni dal veicolo all'infrastruttura (*Vehicle-to-Infrastructure*)

Come diretta conseguenza di questo approccio, è necessario che le informazioni possano essere trasmesse con tempi di latenza estremamente bassi e, a questo scopo, il nuovo standard di comunicazione di quinta generazione (5G) è ottimale. Anche l'elaborazione dei dati viene compiuta nelle vicinanze, per far percorrere al segnale meno strada possibile, attraverso dei *network* di tipo *mobile edge computing* (MEC). Quest'ultima è una tecnologia mediante la quale l'elaborazione dei dati viene eseguita attraverso degli *edge cloud* mobili⁶ posti in prossimità dell'infrastruttura e del veicolo.

Il progetto in questione ha avuto successo e, grazie alle strategie appena discusse, i veicoli autonomi circolanti sono stati in grado di riconoscere immediatamente gli altri utenti della strada, anche in condizioni complicate, potendo adattare di conseguenza la loro strategia di guida.




Figura 4.1: Esempio di come auto e infrastrutture lavorano insieme nella guida autonoma urbana [33].

Il Teoresi Group (azienda torinese che si occupa di servizi di ingegneria con una divisione specializzata sugli AVs), lavorando al futuro della guida autonoma, ha deciso di puntare sia sulla

⁵Mercedes-Benz, Nokia, Osram, TomTom, IT Designers e le Università di Duisburg-Essen e Ulm.

⁶Infrastruttura di *server* delocalizzata e sparsa sul territorio.

realizzazione della connessione con le infrastrutture, che sulla mutua connessione tra gli stessi veicoli, V2V (*Vehicle-to-Vehicle*); tant'è, che oltre al termine *Autonomous Vehicles*, è solita usare **Connected Vehicles** (CV) [34]. L'obiettivo che si pone è quello di rendere ogni singola auto un elemento connesso, **cooperativo**, capace di registrare informazioni mediante telecamere, sensori LiDAR e RADAR, e di comunicarle agli altri mezzi. Nella loro visione, il raggiungimento della completa automazione, avverrà per gradi, riuscendo a realizzare inizialmente degli ambienti controllati in cui potrà essere sperimentata la circolazione, concessa solo ed esclusivamente agli AVs. Queste zone potrebbero essere dei tratti autostradali, delle aree periferiche, ma anche degli interi centri urbani, in grado di eliminare la coesistenza dei veicoli con guidatore. Lo scopo ultimo è quello di riuscire a creare, all'interno di questi spazi, la cosiddetta comunicazione V2X, ovvero, veicolo connesso a tutto (*Vehicle-to-Everything*), in cui le informazioni vengono inviate in rete da qualsiasi elemento possa influenzare lo stato dell'auto, come pedoni, mezzi di assistenza ai disabili (carrozine), ma anche biciclette o dispositivi elettronici in generale. In questo tipo di ambiente controllato, si aprono scenari che offrono un costante monitoraggio dello stato dei veicoli, così da poter gestire in maniera sistematica il traffico ed avere una risposta immediata ed efficace nelle situazioni di pericolo.

4.4 Proiezioni

In accordo con uno studio di Accenture⁷ "*Rebooting Autonomous Driving*" [35], il futuro nell'ambito della guida automatica sarà delineato da una serie di piccoli approcci evolutivi, non da un'unica grande svolta decisiva. Il primo di questi potrebbe essere un netto cambio di rotta da parte delle *Original Equipment Manufacturers*⁸ (OEM), che dovrebbero concentrarsi su una strategia incentrata sulla componente *software*. Questo avverrebbe impiegando le già enormi risorse disponibili (in termini di potenziale numero di veicoli prodotti e venduti o già in circolazione), in modo da poter raccogliere un *dataset* ancora più ricco e diversificato, sfruttando un approccio simile a quello di Tesla.

Secondo le proiezioni fornite dall'azienda, nel corso nei prossimi dieci anni il mercato sarà sempre più popolato da veicoli equipaggiati con il livello 2 di aiuti alla guida, piuttosto che con i livelli più avanzati. La causa si trova nelle difficoltà allo sviluppo di AI sufficientemente affidabili da garantire la sicurezza necessaria all'assenza di supervisione umana. Entro il 2030 è infatti previsto che il 60% dei veicoli disponga almeno del 2° stadio di assistenze [figura 4.2], influenzando, peraltro, in maniera positiva sul bilancio degli incidenti causati dall'errore umano.

Tramite la vasta diffusione di auto fornite di assistenze alla guida di livello 2, introducendo la cosiddetta *shadow mode*⁹ (modalità ombra), le Case potranno lavorare in maniera sicura ed efficace sulla realizzazione di veicoli dotati di *conditional automation* (livello 3), o di tecnologie superiori. Questa modalità consiste nel monitorare ogni veicolo dotato di tecnologia AD¹⁰, in cui il *software* responsabile della guida autonoma è sempre attivo, ma non collegato agli attuatori di movimento. Ciò, permette ai produttori di confrontare il comportamento teorico scelto dalle AI, con quello realizzato dal guidatore.

Per il momento, i livelli 3 e 4 occuperanno cumulativamente solo il 5% del mercato, in quanto, si rivolgeranno rispettivamente solo a veicoli di alta fascia di prezzo o a servizi di taxi e *sharing*, ristretti ad aree isolate. La diffusione di queste ultime tecnologie avverrà presumibilmente durante il prossimo decennio, quando saranno disponibili anche su modelli di fasce più basse di mercato. Volkswagen, ad esempio, ha annunciato di voler equipaggiare l'intera flotta con il livello

⁷ Azienda che fornisce una vasta gamma di servizi e soluzioni nei settori *strategy, consulting, digital, technology e operations*.

⁸ Case automobilistiche classiche.

⁹ Già utilizzata da Tesla sulle sue vetture.

¹⁰ *Autonomous Driving*.

3 di assistenze, però è un'operazione che richiede tempo; in effetti, il loro obiettivo è riuscire ad arrivarci, appunto, entro la metà della prossima decade [36].

Nel contempo, auspicando che a livello nazionale (ed internazionale) vengano stabilite le regolamentazioni dovute, potranno essere organizzate delle aree dedicate, in cui la condizione di autonomia dei suddetti veicoli potrebbe passare al livello 4. La maggiore libertà di distrazione del conducente sarebbe garantita dall'adeguamento delle infrastrutture alle condizioni necessarie. Qui saranno liberi di circolare tutti quei mezzi che garantiscono la sicurezza adeguata, come per altro già avviene in alcuni luoghi (Waymo), ma anche quelle vetture che, ricevendo un maggior numero di dati utili provenienti dalle infrastrutture, riusciranno ad aumentare il proprio livello di automazione momentaneamente dal 3 al 4.




Figura 4.2: Proiezione sui volumi di mercato dei veicoli autonomi inerenti al decennio 2020-2030 [35].

Conclusioni

Il percorso di questo elaborato, articolato in 4 capitoli, ha messo in risalto le possibili applicazioni e le modalità di utilizzo delle reti neurali nel contesto della guida autonoma, che sempre più, al giorno d'oggi, sta diventando di interesse comune. Così, a partire dai primi capitoli, si è cercato di fornire le conoscenze teoriche basilari, che dessero un *background* sulle *Neural Networks*, spiegandone la terminologia, il funzionamento e l'architettura, analizzando le fasi fondamentali dello sviluppo e dell'impiego. In seconda battuta ci si è concentrati su un tipo specifico di rete neurale, ovvero quella Convoluzionale, in quanto responsabile di una delle operazioni fondamentali nel processo di *self driving*: l'*Object Detection*. Ne è stata sottolineata l'importante dipendenza dalla qualità e dalla quantità di dati impiegati nella fase di addestramento, in vista dei capitoli successivi della tesi, in cui è stato poi ripreso il tema.

In seguito l'attenzione è passata all'argomento Guida Autonoma, fornendone inizialmente una rappresentazione storica, descrivendo come le AI primitive sono state utilizzate nel campo, arrivando poi a delineare come le più moderne ne caratterizzino oggi tutto il processo di implementazione. Il passo successivo è stato quello di condurre un'analisi sul metodo utilizzato da tre grandi *Competitors* nel campo per lo sviluppo della tecnologia, affrontando in particolar modo la raccolta e l'utilizzo dei dati utili al *training* delle NNs. Da questo confronto, nel quale sono state comparate le differenze tra le modalità e gli obiettivi delle tre aziende, sono emersi dei punti in comune e, più specificamente, le loro criticità. Tra le varie problematiche oggi esistenti, si è scelto di analizzare quelle legate alle reti che attuano la localizzazione e categorizzazione degli oggetti, uno degli elementi centrali dell'elaborato e, nello specifico, si è approfondita l'architettura YOLO.

Infine si è giunti all'ultimo capitolo (escluso questo delle conclusioni) nel quale sono state inizialmente presentate delle cifre significative per quanto riguarda la sicurezza raggiunta e l'efficacia dei già avanzati sistemi di assistenza alla guida presenti oggi sul mercato, proseguendo con la descrizione degli approcci di risoluzione alle criticità che sono già in fase di *test* o, almeno, in fase di progettazione per il futuro.

Per concludere si sono studiate delle proiezioni, fornite da alcuni esperti del settore e dalle stesse aziende che lavorano sullo sviluppo di questo tipo di tecnologie, riguardanti l'evoluzione delle applicazioni reali nel corso dei prossimi decenni.

È importante tenere presente che quanto esposto in questo elaborato è fortemente legato all'anno, e probabilmente al mese, in cui è stato redatto. L'evoluzione della tecnologia prosegue di giorno in giorno e lo stato dell'arte delle architetture utilizzate muta continuamente.

Ma solo partendo da qui, da quello che conosciamo oggi, si può lavorare per raggiungere un futuro migliore in termini di sicurezza e qualità di esperienza.

Il compito di realizzare questo futuro spetta all'Ingegnere:

"Strive for perfection in everything you do. Take the best that exists and make it better. When it does not exist, design it".

Sir Henry Royce [37].

Bibliografia e Sitografia

- [1] Caprino Maurizio. «Fino a 130 km all'ora per le auto con guida autonoma di livello 3.» In: // *Sole 24 Ore* (2022). URL: <https://www.ilsole24ore.com/art/fino-130-km-all-ora-le-auto-guida-autonoma-livello-3-AEJPSULC>.
- [2] «The 6 Levels of Vehicle Autonomy Explained». In: *Synepsys* (2023). URL: <https://www.synepsys.com/automotive/autonomous-driving-levels.html>.
- [3] «Incidenti stradali in Italia anno 2019». In: *ANSA* (2020), p. 1. URL: <https://www.istat.it/it/files//2020/07/Incidenti-stradali-in-Italia-Anno-2019-aggiornamento-27ottobre2020.pdf>.
- [4] «Le statistiche sugli incidenti stradali mortali nell'UE». In: *Parlamento europeo* (2019). URL: <https://www.europarl.europa.eu/news/it/headlines/society/20190410ST036615/le-statistiche-sugli-incidenti-stradali-mortali-nell-ue-infografica>.
- [5] Lex Fridman ricercatore MIT sull'auto a guida autonoma e Human centred AI. In: (2023). URL: <https://lexfridman.com/>.
- [6] Nikita Sharma. «Introduction to basic object detection algorithms». In: *Medium* (2019). URL: <https://heartbeat.comet.ml/introduction-to-basic-object-detection-algorithms-b77295a95a63>.
- [7] «Reti neurali, cosa sono?» In: *Intelligenza Artificiale* (2023). URL: <https://www.intelligenzaartificiale.it/reti-neurali/>.
- [8] «IBM Cloud Learn Hub». In: *IBM* (2020). URL: <https://www.ibm.com/it-it/cloud/learn>.
- [9] «Data is the New Currency». In: *Fraunhofer Fokus* (2023). URL: <https://www.fokus.fraunhofer.de/en/fame/workingareas/ai>.
- [10] In: *Stack Overflow* (2023). URL: <https://stackoverflow.com/questions/63883842/can-relu-be-used-at-the-last-layer-of-a-neural-network>.
- [11] «Mathematics behind the Neural Network». In: *Study Machine Learning* (2023). URL: <https://studymachinelearning.com/mathematics-behind-the-neural-network/>.
- [12] Goglia Diletta. «Backpropagation for Dummies». In: *Medium* (2021). URL: <https://medium.com/analytics-vidhya/backpropagation-for-dummies-e069410fa585>.
- [13] Johnson Daniel. «Back Propagation in Neural Network: Machine Learning Algorithm». In: *Guru99* (2022). URL: <https://www.guru99.com/backpropagation-neural-network.html>.
- [14] «Matrice di convoluzione». In: (2023). URL: <https://docs.gimp.org/2.8/it/plugin-convmatrix.html>.
- [15] «Reti neurali convoluzionali». In: *Mathworks* (2023). URL: <https://it.mathworks.com/discovery/convolutional-neural-network-matlab.html#come-funzionano>.

- [16] Pomerleau Dean A. «ALVINN: AN AUTONOMOUS LAND VEHICLE IN A NEURAL NETWORK». In: (1988). URL: <https://proceedings.neurips.cc/paper/1988/file/812b4ba287f5ee0bc9d43bbf5bbe87fb-Paper.pdf>.
- [17] Seno Alvisè-Marco. «Guida autonoma, un sogno partito quasi cent'anni fa». In: *Ruoteclassiche* (2017). URL: <https://ruoteclassiche.quattroruote.it/guida-autonoma-un-sogno-partito-quasi-centanni-fa/>.
- [18] In: *ResearchGate* (2023). URL: https://www.researchgate.net/figure/Demonstration-vehicle-VaMP-of-UniBwM-top-right-a-twin-to-the-Daimler-VITA-2-top-left_fig1_341211118.
- [19] Richard Bellman. «A Markovian Decision Process». In: *Indiana University Mathematics Journal* 6.4 (1957), pp. 679–684.
- [20] Nilesch Barla. «Self-Driving Cars With Convolutional Neural Networks (CNN)». In: *neptine.ai* (2023). URL: <https://neptune.ai/blog/self-driving-cars-with-convolutional-neural-networks-cnn>.
- [21] «Safety». In: *Waymo* (2023). URL: <https://waymo.com/safety/>.
- [22] «Tesla supera quota 1 Milione di auto nel 2022». In: *Autoprove.it* (2023). URL: <https://www.autoprove.it/2023/01/04/tesla-supera-quota-1-milione-di-auto-nel-2022/#:~:text=Da%5C%20sola%5C%20%5C%C3%5C%A8%5C%20stata%5C%20incarinata,del%5C%20totale%5C%20delle%5C%20auto%5C%20prodotte..>
- [23] «Tesla Sales, Revenue & Production for 2023: The Complete Statistics». In: *Tridens technology* (2023). URL: <https://tridens technology.com/tesla-sales-statistics/#h-tesla-car-sales-by-year>.
- [24] «Waymo Driver». In: *Sito Waymo* (2023). URL: <https://waymo.com/waymo-driver/>.
- [25] «NVIDIA: Quando il coraggio porta al successo». In: *Inside Hardware* (2013). URL: <https://web.archive.org/web/20131029203250/http://www.insidehardware.it/hardware/schede-video/2422-nvidia-quando-il-coraggio-porta-al-successo#content>.
- [26] Cragun Matt. «Reconstructing the Real World in DRIVE Sim With AI». In: *nVIDIA* (2022). URL: <https://blogs.nvidia.com/blog/2022/09/20/drive-sim-neural-reconstruction-engine/>.
- [27] «ImageNet». In: *Developedia* (2018). URL: <https://devopedia.org/imagenet#:~:text=A1%5C%2DA.,of%5C%20over%5C%2014%5C%20million%5C%20images>.
- [28] Boesch Gaudenz. «YOLOv7: The Most Powerful Object Detection Algorithm (2023 Guide)». In: *viso.ai* (2023). URL: <https://viso.ai/deep-learning/yolov7-guide/>.
- [29] Redmon Joseph. «You Only Look Once: Unified, Real-Time Object Detection». In: *arXiv* (2016), p. 2. URL: <https://arxiv.org/pdf/1506.02640.pdf>.
- [30] Kundu Rohit. «YOLO: Algorithm for Object Detection Explained [+Examples]». In: *v7 Labs* (2023). URL: <https://www.v7labs.com/blog/yolo-object-detection#h2>.
- [31] Aimone Cat Gabriele. «Studio Bosch – ACI sull'efficacia dei sistemi di assistenza alla guida (ADAS)». In: *Bosch* (2019). URL: <https://www.bosch-press.it/pressportal/it/it/press-release-39936.html>.
- [32] Gemelli Fabio. «Adas obbligatori, ecco cosa diventa indispensabile per circolare». In: *Motor1* (2022). URL: <https://it.motor1.com/news/596569/adas-obbligatori-auto/>.

- [33] Aimone Cat Gabriele. «Come le auto e le infrastrutture lavorano insieme nella guida autonoma urbana». In: *Bosch* (2020). URL: <https://www.bosch-press.it/pressportal/it/it/press-release-47552.html>.
- [34] «Connected Vehicles». In: *Teoresi* (2023). URL: <https://www.teoresigroup.com/it/solutions/connected-vehicles/>.
- [35] «Rebooting Autonomous Driving». In: *Accenture* (2021). URL: <https://www.accenture.com/content/dam/accenture/final/a-com-migration/r3-3/pdf/pdf-169/accenture-rebooting-autonomous-driving.pdf#zoom=40>.
- [36] «Die Automated Driving Platform ist ein maßgeschneidertes Werkzeug». In: *Volkswagen Group News* (2021). URL: <https://www.volkswagen-newsroom.com/de/storys/die-automated-driving-platform-ist-ein-massgeschneidertes-werkzeug-6808>.
- [37] «Rolls-Royce Motor Cars exhibition». In: *BMW Welt* (2007). URL: https://www.bmw-welt.com/en/experience/popups/exhibition_welt/strive-for-perfection.html#:~:text=Rolls%5C%2DRoyce%5C%20Motor%5C%20Cars%5C%20exhibition.&text=%5C%E2%5C%80%5C%9CStrive%5C%20for%5C%20perfection%5C%20in%5C%20everything,which%5C%20is%5C%20still%5C%20valid%5C%20today..

Ringraziamenti

Vorrei approfittare di quest'ultima pagina per ringraziare tutti coloro che mi hanno accompagnato fin qui, quelle persone che mi hanno preso per mano, rendendo possibile il raggiungimento di questo obiettivo. Per me non si tratta di una semplice *Laurea Triennale*, è piuttosto il risultato conseguito alla fine di un lungo percorso che è andato spesso al di là della vita universitaria.

La prima persona che tengo a ringraziare è il Professor Rech, perché oltre ad aiutarmi durante tutto il percorso di scrittura della tesi, guidandomi verso questo elaborato finale, è riuscito a trasmettermi la passione per un campo dell'ingegneria che spero di poter approfondire nel futuro, rendendolo un giorno parte della vita professionale.

Rimanendo nell'ambito universitario, è d'obbligo un ringraziamento al grande collega e amico Nicola. Senza di te non sarebbe stata la stessa cosa; abbiamo percorso questa strada insieme passo per passo, rendendola più leggera e divertente.

Successivamente, il GRAZIE più grande va alla mia famiglia, che non ha mai mollato insieme a me, che ha permesso che tutto questo fosse possibile. A mamma Loredana e a papà Fausto, a Paolo e a Ilaria, che oltre a cercare con me le soluzioni, siete riusciti a farmi ridere ad ogni aperitivo, ad ogni cena e ad ogni festa. Grazie di tutto.

Poi gli amici, vecchi e nuovi, andati e venuti, perché ognuno di voi mi ha dato qualcosa, sia nei momenti belli che in quelli di brutti.

Ad Irina e ad Alessandro; a voi che più di chiunque altro siete stati in prima linea per tutti questi anni, l'*élite* che ha avuto l'onere (e spero anche l'onore) di vedere sempre il vero me. Senza di voi i giorni sarebbero passati molto più lentamente. Preparatevi perché, purtroppo per voi, non è ancora finita.

A Paolo S.; a te che sei stato con me dal giorno zero, in grado di spronarmi da sempre a dare di più. Probabilmente senza la tua presenza non sarei la persona che sono oggi. Grazie.

L'ultimo ringraziamento, non di sicuro per importanza, va ad Alberto. Dalla prima monoposto (Ferrari ovviamente) costruita con i Lego assieme a papà a Natale, passando poi ai musei, alle spiegazioni tecniche e alle conversazioni infinite sulle auto andando verso il mare (povera Zia). Senza di te non avrei scelto questo percorso, hai acceso la scintilla, grazie di cuore.